Projeto - Aplicação de Redes Neurais Objetivo: O aluno deverá ser capaz de realizar uma análise completa dos dados e projetar uma rede neural para resolver o problema. Avaliar os resultados obtidos através das métricas de classificação Problema: De posse de dados que correspondem a sinais de transitórios de eletrodomésticos (sinais obtidos em uma janela de 2s ao se ligar equipamento) e que foram ortudados em 7 diferentes classes, o punto deverá realizar os seguintes passos: 1) Carregar os dados e realizar a limpeza dos dados (se necessário) 2) Visualizar os dados para compreensão (dica: plotar 1 exemplo de cada Classe). Como na Figura 1, abaixo, que representa um eletrodoméstico da Classe 13) Como é um problema muticlasse, o aluno deverá transformar os labels para uma representação correta. 4) Preparar os dados para se apresentados à Mt. 5) Construir a rede neural como seus respectivos parámetros (taxa de aprendizado, númeir o de camadas intermediárias, número de neurônios, batch\_size etc). O aluno deve propor uma estratégia para determinar esses parámetros. 6)
Testar e validar os resultados 7) Avaliar o usa de PCA (Análise de Componentes Principais) para visualização dos dados e também como speed-up da ML (para finas de classificação). 8) Concluses.

```
import pandas as pd
import nampy as rp
import matpolith.psplot as plt
import matpolith.psplot as plt
import assessment as ses
frem ydata_profile.psplot neither
frem ydata_profile.psplot neither
import seaborn as ses
frem skienn.psprocessing import OmelotEncoder, Standard
from skienn.model_selection import train_test_split
from skienn.model_selection import train_test_split
from skienn.model_selection import train_test_split
from skienn.model_selection import foridSearchV
from skienn.moderics import classification_report
from skienn.moderics import classification_report
from skienn.moderics import classification_report, confus
from skienn.moderics import classification_report.
                                          t0 t1 t2 t3 t4 t5 t6 t7 t8 t9 ... t191 t192 t193 t194 t195 t196 t197 t198 t199 Classes

        1
        t1
        t2
        t3
        t4
        t5
        t6
        t7
        t8
        t9
        ...
        t31
        t32
        t34
        <
                    t0
t1
t2
t3
t4
                    array([1, 2, 3, 4, 5, 6, 7], dtype=
               PlotGraf(df,classe,linha): #código para plotar os gáficos
df_fig = df[df['Classes'] == classe]
fig = df_fig.iloc(linha,:-1].plot(figsize = (8, 2))
plt.show()
                            0.00
                         10
                                                    175 H100 H125 H50 H76
                                                      5.0
                       2.5
                       20
                                                         t50 t75 t100 t125 t150
                                                  managan Araban managan managan
                                                                                                                    t50 t75
```

```
X = df.drop('Classes', axis=1)
y = labels_
grid_search = GridSearchCV(clf, parameters, n_jobs=-1, cv=5)
```

```
► MLPClassifier ①
# Avaliando o desempenho do modelo com os melhores parâmetros no conjunto
best_clf = grid_search_best_estimator_
accuracy = best_clf.score(X_test, y_test)
print("Acuracia no conjunto de teste com melhores parâmetros:", accuracy)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=20
```

clf nra = MLPClassifier(random state=1.hidden lawer sizes= (20.1.learning rate init=0.01. max iter=200. Mrolocando com os melhores hineroarâmetros do gridsearch

```
wrbose-True).fit(x train pca, y_train)

② Iteration 1, loss = 10.60908509
Iteration 2, loss = 15.50805303
Iteration 6, loss = 5.7.80820843
Iteration 6, loss = 6.7.80820843
Iteration 6, loss = 6.7.80820843
Iteration 8, loss = 4.48480721
Iteration 9, loss = 4.48480721
Iteration 19, loss = 4.48480721
Iteration 19, loss = 4.68480721
Iteration 19, loss = 4.84480721
Iteration 19, loss = 5.6948078
Iteration 11, loss = 3.5084078
Iteration 11, loss = 3.5084078
Iteration 13, loss = 3.6948078
Iteration 13, loss = 3.6948078
Iteration 13, loss = 2.6928079
Iteration 15, loss = 2.9829079
Iteration 15, loss = 2.9829079
Iteration 15, loss = 2.9829079
Iteration 18, loss = 2.9829079
Iteration 18, loss = 2.9829079
Iteration 17, loss = 2.8980239
Iteration 18, loss = 2.78278077
Iteration 18, loss = 2.78278077
Iteration 18, loss = 2.78278077
Iteration 21, loss = 2.8929737
Iteration 21, loss = 2.8929737
Iteration 21, loss = 2.8929737
Iteration 28, loss = 2.7827807
Iteration 38, loss = 2.1716649
Iteration 38, loss = 2.1716649
Iteration 38, loss = 2.1717669
Iteration 38, loss = 2.1717669
Iteration 38, loss = 2.1717669
Iteration 38, loss = 1.8927999
Iteration 48, loss = 1.8927999
Iteration 48, loss = 1.8927999
Iteration 48, loss = 1.8927997
Iteration 48, loss = 1.8927997
Iteration 49, loss = 1.8980207
Iteration 49, loss = 1.8980207
Iteration 40, loss = 1.79195238
Iteration 50, loss = 1.79195238
Iteration 50, loss = 1.79195238
Iteration 50, loss = 1.79195238
Iteration 50,
```